

1. 使用的 AI 模型

我使用了 Codex 中的 AI 助手，具体模型为：___GPT-6 sol___。

2. 使用的 AI 提示词

我主要通过多轮对话提出问题，代表性的提示词包括：

- “这个需要在虚拟机当中完成吗，还是在我本地的 Windows 就可以完成？”
- “我的电脑没有英伟达显卡，只有核显，怎么解决这个问题。”
- “启动失败了。”我提供了运行日志，请 AI 分析原因。
- “SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分？这个问题的答案可以从论文的哪里获取？”

3. AI 如何帮助我学习，以及在哪些方面使用了 AI

在环境准备与部署方面，AI 帮助我拆解任务、判断本机硬件条件、选择云端 GPU，并提供安装和启动命令。在遇到问题时，我将日志提供给 AI，借助它分析模型下载失败、CUDA 编译工具版本不匹配和运行库搜索路径等问题。

在实验方面，AI 帮助我编写 workload 脚本，实现 trace 采样、模拟提示词构造、Poisson 到达过程和实验指标记录，并解释返回结果、token 数和总延迟的含义。

在理论学习方面，AI 帮助我定位论文中与作业相关的章节，解释 KV Cache、RadixAttention 和 PagedAttention 等概念，并协助梳理它们的联系与区别。我再结合翻译工具和英文原文进行阅读与核对。AI 也帮助我整理流程图思路和报告文字。

4. 使用 AI 时是否受到误导

使用过程中，AI 的指导存在不完整的地方。例如，它建议选择预装 CUDA 11.8 的基础镜像，却没有提前说明当前安装的依赖在编译时需要更新的 CUDA 工具包，导致服务启动失败。随后，安装 CUDA 13 工具包后，又因为库搜索路径未配置完整而出现链接错误。经过提供日志、分析原因和调整配置，最终才成功启动服务。

此外，我最初将返回结果中的 Unicode 转义误认为模型没有回答。AI 解释后，我确认这是中文的显示方式，并调整了输出格式。

这些经历让我认识到，AI 的回答不能直接视为正确结论。我需要结合官方资料、论文原文、错误日志和实际运行结果进行验证，也需要如实说明 AI 对代码编写和报告整理的帮助。